

MODELADO DEL CAUDAL NATURAL EN LA CUENCA HIDROGRÁFICA CHAMBO CON REDES NEURONALES

Anabela R. Turlione

Master en Data Science - Universidad de Cantabria

Septiembre 2022

Introducción

Motivación

Objetivos

Metodología

Datos

Series meteorológicas

Variables objetivo: Caudales de descarga

Modelo MODSIM

Modelos de Aprendizaje Profundo

Redes recurrentes con memoria a largo plazo

Topología de los modelos utilizados

Entrenamiento de los modelos

Resultados

Conclusiones

En este trabajo se ha evaluado el desempeño de diferentes modelos de redes neuronales para predecir el caudal natural en la cuenca hidrográfica Chambo a partir de series de entrada hidro-climáticas.

Motivación

- ▶ Los modelos hidrológicos tradicionales no son extrapolables en el espacio.

Motivación

- ▶ Los modelos hidrológicos tradicionales no son extrapolables en el espacio.
- ▶ ¿Cómo extraer información hidrológica de un área a otra?

Motivación

- ▶ Los modelos hidrológicos tradicionales no son extrapolables en el espacio.
- ▶ ¿Cómo extraer información hidrológica de un área a otra?
- ▶ ¿Es esto posible? ¿Existe una teoría hidrológica válida a macro escalas?

Motivación

- ▶ Los modelos hidrológicos tradicionales no son extrapolables en el espacio.
- ▶ ¿Cómo extraer información hidrológica de un área a otra?
- ▶ ¿Es esto posible? ¿Existe una teoría hidrológica válida a macro escalas?
- ▶ Avances en ML, DP

Motivación

- ▶ Los modelos hidrológicos tradicionales no son extrapolables en el espacio.
- ▶ ¿Cómo extraer información hidrológica de un área a otra?
- ▶ ¿Es esto posible? ¿Existe una teoría hidrológica válida a macro escalas?
- ▶ Avances en ML, DP →

Motivación

- ▶ Los modelos hidrológicos tradicionales no son extrapolables en el espacio.
- ▶ ¿Cómo extraer información hidrológica de un área a otra?
- ▶ ¿Es esto posible? ¿Existe una teoría hidrológica válida a macro escalas?
- ▶ Avances en ML, DP → es posible derivar un modelo global a partir de los datos

Objetivos

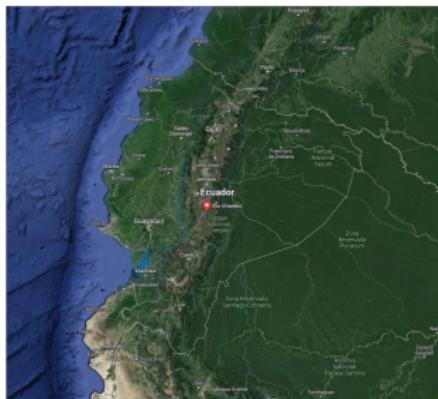
Evaluar la performance de redes neuronales en la

Objetivos

Evaluar la performance de redes neuronales en la **cuenca hidrográfica del río chambo en Ecuador (CHRC)**.

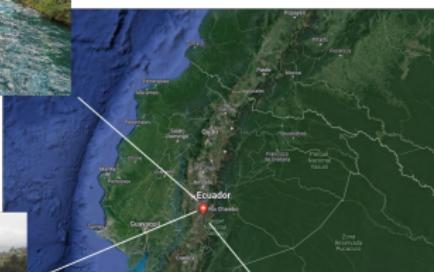
Objetivos

Evaluar la performance de redes neuronales en la **cuenca hidrográfica del río chambo en Ecuador (CHRC)**.



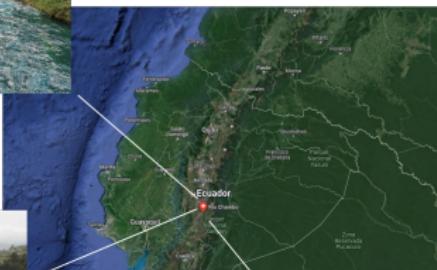
Objetivos

Evaluar la performance de modelos de redes neuronales en la cuenca hidrográfica del río Chambo en Ecuador.



Objetivos

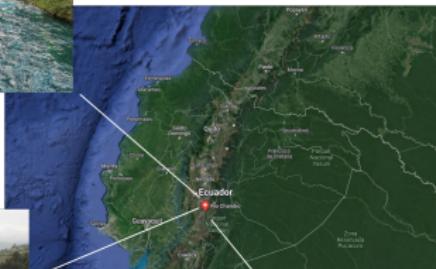
Evaluar la performance de modelos de redes neuronales en la cuenca hidrográfica del río Chambo en Ecuador.



- ▶ 33 ríos de tamaños muy variables.

Objetivos

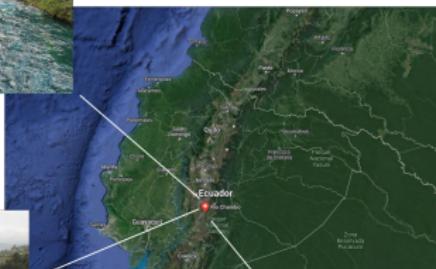
Evaluar la performance de modelos de redes neuronales en la cuenca hidrográfica del río Chambo en Ecuador.



- ▶ 33 ríos de tamaños muy variables.
- ▶ Fuertes pendientes, alturas máximas ~ 6000 m.s.n.m.

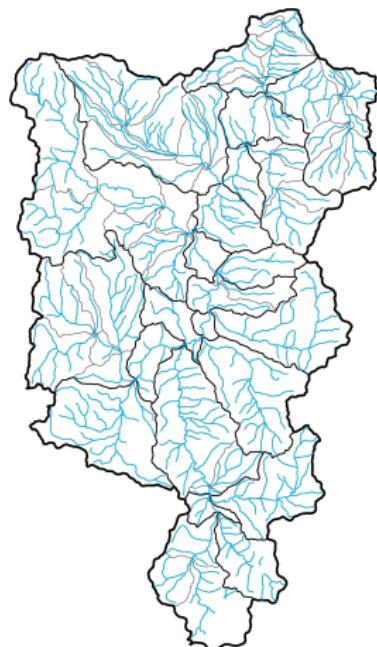
Objetivos

Evaluar la performance de modelos de redes neuronales en la cuenca hidrográfica del río Chambo en Ecuador.

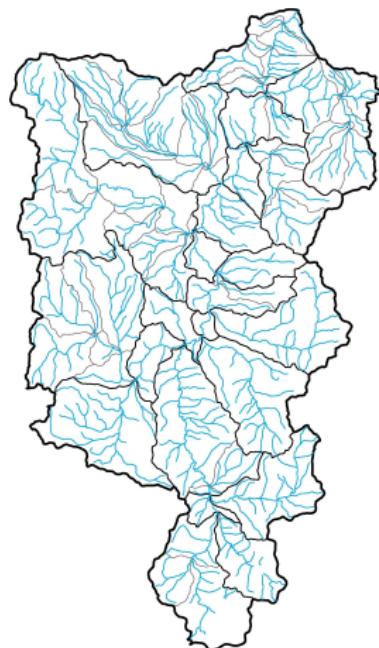


- ▶ 33 ríos de tamaños muy variables.
- ▶ Fuertes pendientes, alturas máximas ~ 6000 m.s.n.m.
- ▶ Subdivisión en 76 sub-cuencas (método Pfastetter con 7 niveles).

Metodología

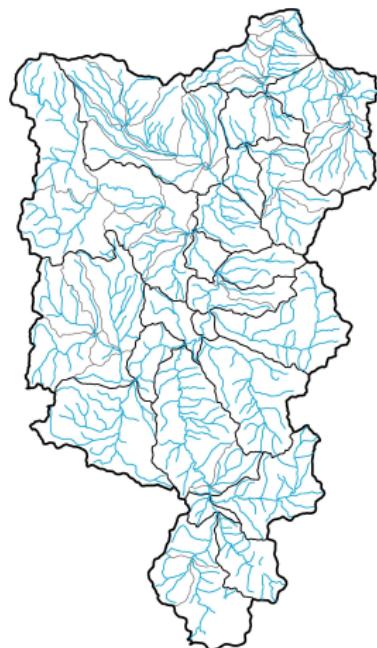


Metodología



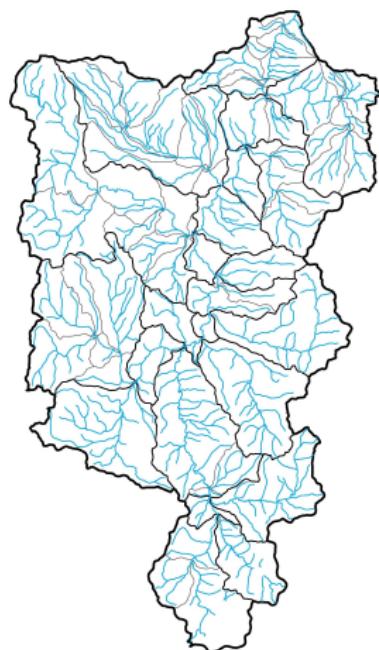
- ▶ Se han entrenado modelos de redes neuronales en las 76 sub-cuencas que conforman CHRC.

Metodología



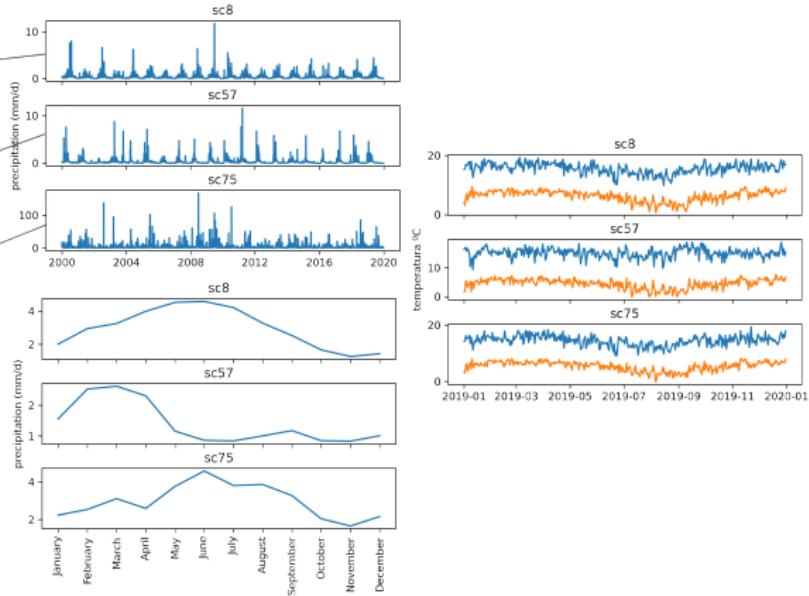
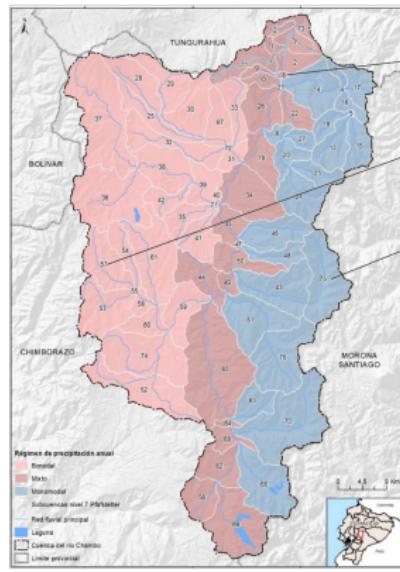
- ▶ Se han entrenado modelos de redes neuronales en las 76 sub-cuencas que conforman CHRC.
- ▶ Datos de entrenamiento: datos meteorológicos (series de precipitación y temperatura).

Metodología



- ▶ Se han entrenado modelos de redes neuronales en las 76 sub-cuenca que conforman CHRC.
- ▶ Datos de entrenamiento: datos meteorológicos (series de precipitación y temperatura).
- ▶ Variables objetivo: caudales de descarga en cada subcuenca.

Datos de entrenamiento: series meteorológicas



Variables objetivo: Caudales de descarga

Variables objetivo: Caudales de descarga

- ▶ Simulados con MELCA (Modelo de Equilibrio Logístico para Cuencas Andinas)

Variables objetivo: Caudales de descarga

- ▶ Simulados con MELCA (Modelo de Equilibrio Logístico para Cuencas Andinas) → las cuencas hidrográficas son sistema que continuamente persiguen un equilibrio dinámico.

Variables objetivo: Caudales de descarga

- ▶ Simulados con MELCA (Modelo de Equilibrio Logístico para Cuencas Andinas) → las cuencas hidrográficas son sistema que continuamente persiguen un equilibrio dinámico.
- ▶ Modelo agregado (al igual que el SAC-SMA).

Variables objetivo: Caudales de descarga

- ▶ Simulados con MELCA (Modelo de Equilibrio Logístico para Cuencas Andinas) → las cuencas hidrográficas son sistema que continuamente persiguen un equilibrio dinámico.
- ▶ Modelo agregado (al igual que el SAC-SMA).
- ▶ Ecuaciones simples, pocos parámetros (típicamente 4-7).

Variables objetivo: Caudales de descarga

- ▶ Simulados con MELCA (Modelo de Equilibrio Logístico para Cuencas Andinas) → las cuencas hidrográficas son sistema que continuamente persiguen un equilibrio dinámico.
- ▶ Modelo agregado (al igual que el SAC-SMA).
- ▶ Ecuaciones simples, pocos parámetros (típicamente 4-7).
- ▶ Se calibran con datos observados cuenca por cuenca.

Variables objetivo: Caudales de descarga

- ▶ Simulados con MELCA (Modelo de Equilibrio Logístico para Cuencas Andinas) → las cuencas hidrográficas son sistema que continuamente persiguen un equilibrio dinámico.
- ▶ Modelo agregado (al igual que el SAC-SMA).
- ▶ Ecuaciones simples, pocos parámetros (típicamente 4-7).
- ▶ Se calibran con datos observados cuenca por cuenca.
- ▶ No son extrapolables en el espacio (el modelo de una cuenca no es válido para otra).

MELCA

Precipitación → Escorrentía (runoff)

MELCA

Precipitación → Escorrentía (runoff)

$$\frac{dR(t)}{dt} = \frac{P(t)}{S_0} \cdot R(t) \cdot \left(1 - \frac{R(t)}{R_{eq}}\right)$$

MELCA

Precipitación → Escorrentía (runoff)

$$\frac{dR(t)}{dt} = \frac{P(t)}{S_0} \cdot R(t) \cdot \left(1 - \frac{R(t)}{R_{eq}}\right)$$

Evolución de la escorrentía

MELCA

$$\frac{dR(t)}{dt} = \frac{P(t)}{S_0} \cdot R(t) \cdot \left(1 - \frac{R(t)}{R_{eq}}\right)$$

MELCA

$$\frac{dR(t)}{dt} = \frac{P(t)}{S_0} \cdot R(t) \cdot \left(1 - \frac{R(t)}{R_{eq}}\right)$$

Espesor característico del suelo

MELCA

$$\frac{dR(t)}{dt} = \frac{P(t)}{S_0} \cdot R(t) \cdot \left(1 - \frac{R(t)}{R_{eq}}\right)$$

MELCA

$$\frac{dR(t)}{dt} = \frac{P(t)}{S_0} \cdot R(t) \cdot \left(1 - \frac{R(t)}{R_{eq}}\right)$$

Escojertería de equilibrio:

$$R_{eq}(t) = P(t) \cdot C_{eq}(\psi); \quad C_{eq}(\psi) = e^{-a \cdot \psi}, \psi = \frac{\hat{E}}{\hat{P}}$$

MELCA

$$\frac{dR(t)}{dt} = \frac{P(t)}{S_0} \cdot R(t) \cdot \left(1 - \frac{R(t)}{R_{eq}}\right)$$

$$\frac{d\hat{P}}{dt} = \frac{P(t) - \hat{P}}{\lambda}$$

$$\frac{d\hat{E}}{dt} = \frac{E(t) - \hat{E}}{\lambda}$$

Tiempo característico de respuesta de la cuenca \sim días

MELCA

$$\frac{dR(t)}{dt} = \frac{P(t)}{S_0} \cdot R(t) \cdot \left(1 - \frac{R(t)}{R_{eq}}\right)$$

$$\frac{d\hat{P}}{dt} = \frac{P(t) - \hat{P}}{\lambda}$$

$$\frac{d\hat{E}}{dt} = \frac{E(t) - \hat{E}}{\lambda}$$

$$\frac{dQ(t)}{dt} = \frac{1}{\tau} \cdot [R(t) - Q(t)]$$

Descarga en la salida de la cuenca

MELCA

$$\frac{dR(t)}{dt} = \frac{P(t)}{S_0} \cdot R(t) \cdot \left(1 - \frac{R(t)}{R_{eq}}\right)$$

$$\frac{d\hat{P}}{dt} = \frac{P(t) - \hat{P}}{\lambda}$$

$$\frac{d\hat{E}}{dt} = \frac{E(t) - \hat{E}}{\lambda}$$

$$\frac{dQ(t)}{dt} = \frac{1}{\tau} \cdot [R(t) - Q(t)]$$

Parámetro de enrutamiento, tiempo de respuesta rápido \sim horas

Calibración

Calibración

- ▶ El modelo es calibrado en cada sub-cuenca de manera individual.

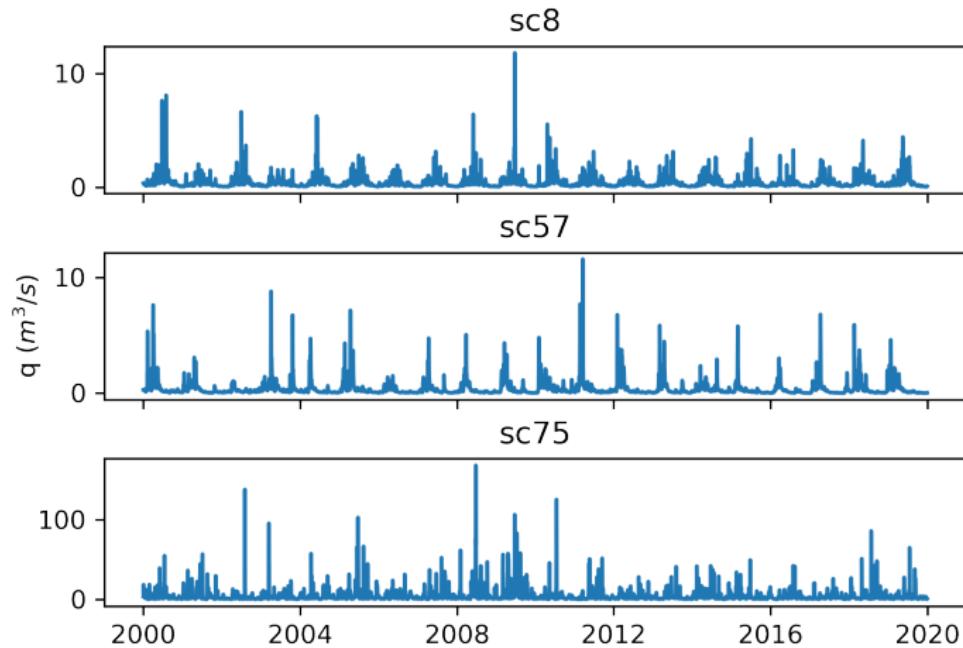
Calibración

- ▶ El modelo es calibrado en cada sub-cuenca de manera individual.
- ▶ A través de los factores fcp y fce que tienen en cuenta la influencia de la altitud de cada subcuenca y corrigen las series de precipitaciones y evo-transpiración.

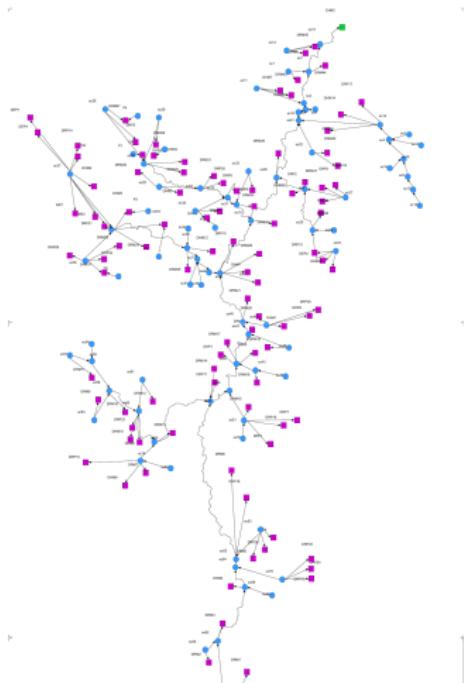
Calibración

- ▶ El modelo es calibrado en cada sub-cuenca de manera individual.
- ▶ A través de los factores fcp y fce que tienen en cuenta la influencia de la altitud de cada subcuenca y corrigen las series de precipitaciones y evo-transpiración.
- ▶ Se ajustan de modo tal que los caudales mensuales medios simulados se acerquen lo más posible a los valores medidos en las estaciones de aforo.

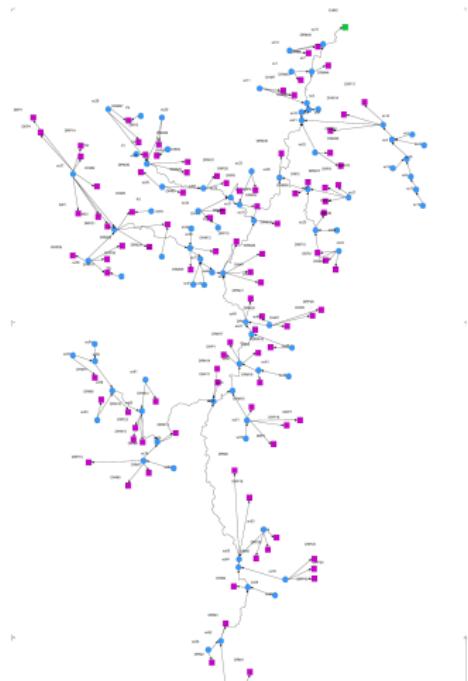
Caudales simulados



Balance hidrológico con MODSIM

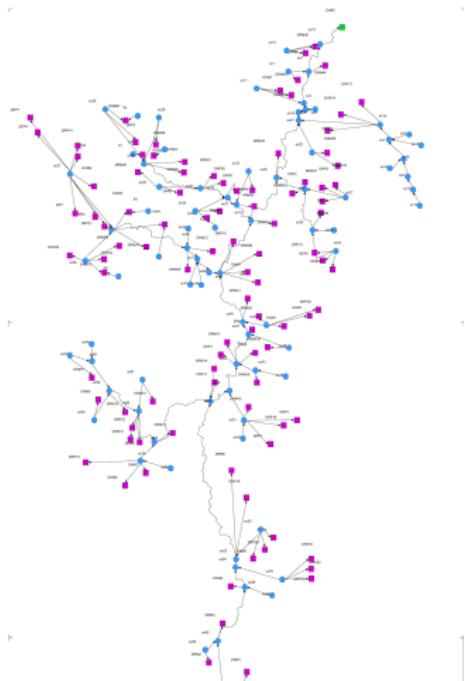


Balance hidrológico con MODSIM



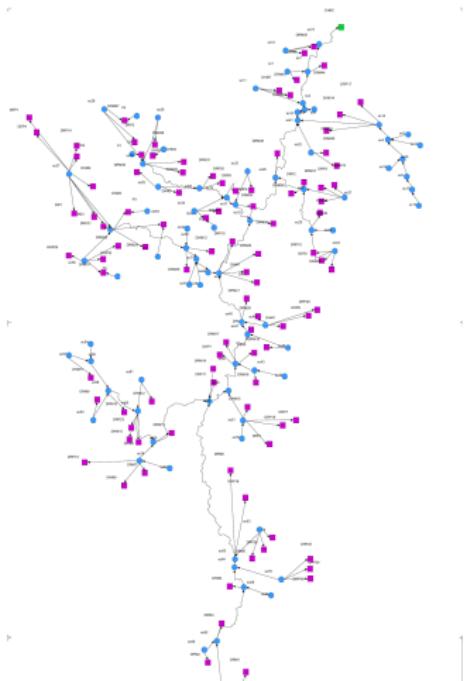
- ▶ Modelo conceptual de la cuenca (con nodos y enlaces).

Balance hidrológico con MODSIM



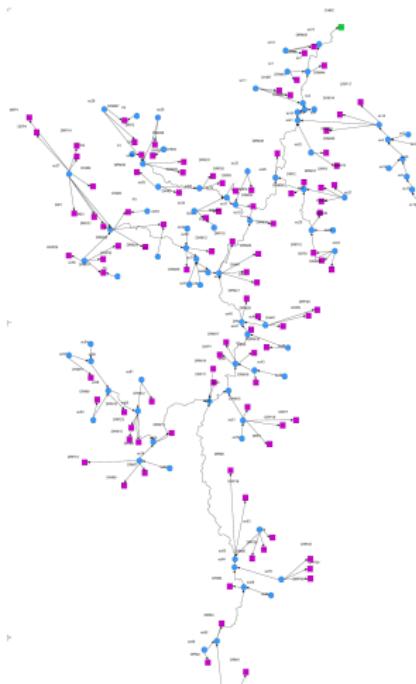
- ▶ Modelo conceptual de la cuenca (con nodos y enlaces).
- ▶ Se puede establecer prioridades en los nodos.

Balance hidrológico con MODSIM



- ▶ Modelo conceptual de la cuenca (con nodos y enlaces).
- ▶ Se puede establecer prioridades en los nodos.
- ▶ Se optimiza la distribución del agua minimizando la función:
$$\sum_{k \in A} c_k \cdot q_k.$$

Balance hidrológico con MODSIM



- ▶ Modelo conceptual de la cuenca (con nodos y enlaces).
- ▶ Se puede establecer prioridades en los nodos.
- ▶ Se optimiza la distribución del agua minimizando la función:
$$\sum_{k \in A} c_k \cdot q_k.$$
- ▶ Conservando el balance de masa:
$$\sum_{k \in O_i} q_k - \sum_{j \in I_i} q_j = b_{it}(q),$$

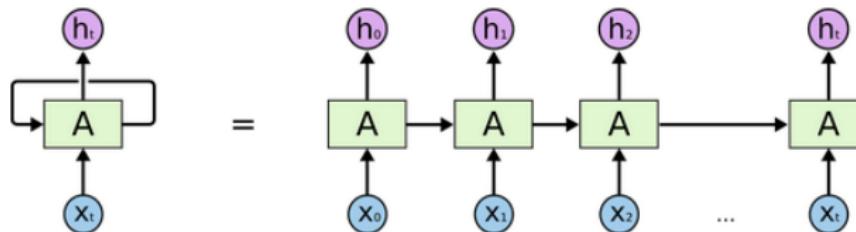
$$l_{kt} < q_k < u_{kt}.$$

Modelos de Aprendizaje Profundo

Se han utilizado redes neuronales recurrentes.

Modelos de Aprendizaje Profundo

Se han utilizado redes neuronales recurrentes.

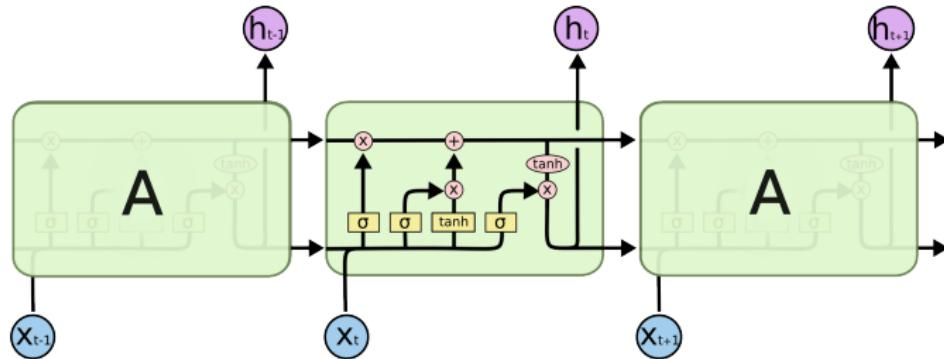


Redes LSTM

En particular, se han considerado redes recurrentes con memoria a largo y corto plazo.

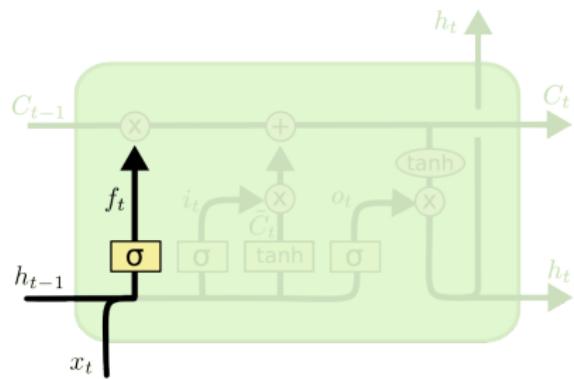
Redes LSTM

En particular, se han considerado redes recurrentes con memoria a largo y corto plazo.



Redes LSTM

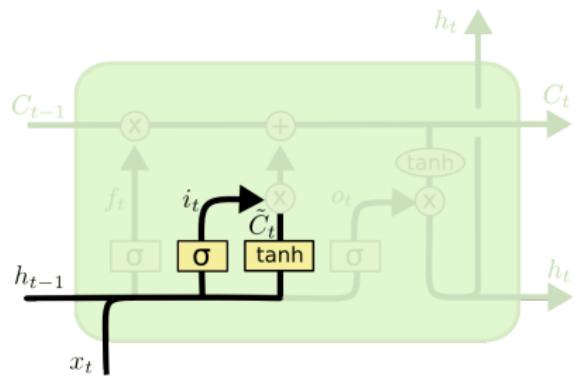
“Forget gate layer”: qué parte debe olvidarse



$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

Redes LSTM

“Input gates”: calculan el “cambio” y cual es el peso de este “cambio” ...

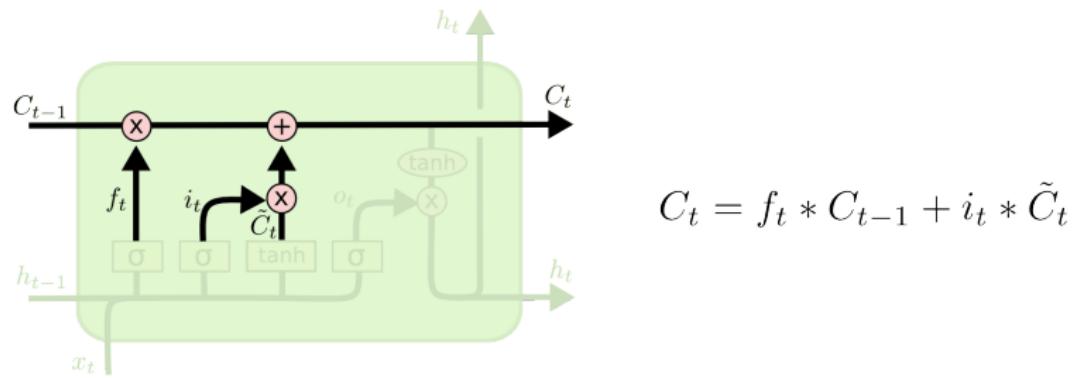


$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

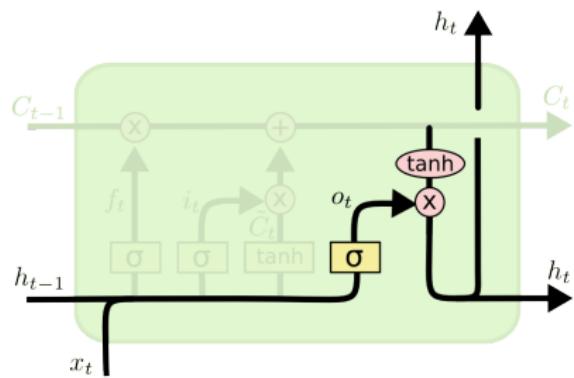
Redes LSTM

“Input gates”: y actualizan el estado de la celda.



Redes LSTM

“Output gate”: Calcula la salida



$$o_t = \sigma(W_o [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t * \tanh(C_t)$$

Topología de los modelos utilizados

1. Modelo Denso: Consta de dos capas densas

Topología de los modelos utilizados

- 1. Modelo Denso:** Consta de dos capas densas
- 2. Modelo LSTM1:** Contiene una capa LSTM y una segunda capa densa.

Topología de los modelos utilizados

1. **Modelo Denso:** Consta de dos capas densas
2. **Modelo LSTM1:** Contiene una capa LSTM y una segunda capa densa.
3. **Modelo LSTM2:** Consta de dos capas LSTM y una capa densa.

Entrenamiento global

Matriz de características:

$$X_{comp} = \begin{bmatrix} p_{1,1} & T_{1,1}^{max} & T_{1,1}^{min} & \dots & p_{1,nc} & T_{1,nc}^{max} & T_{1,nc}^{min} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ p_{nt,1} & T_{nt,1}^{max} & T_{nt,1}^{min} & \dots & p_{nt,n} & T_{nt,n}^{max} & T_{nt,nc}^{min} \end{bmatrix}$$

Entrenamiento global

Matriz de características:

$$X_{comp} = \begin{bmatrix} p_{1,1} & T_{1,1}^{max} & T_{1,1}^{min} & \dots & p_{1,nc} & T_{1,nc}^{max} & T_{1,nc}^{min} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ p_{nt,1} & T_{nt,1}^{max} & T_{nt,1}^{min} & \dots & p_{nt,n} & T_{nt,n}^{max} & T_{nt,nc}^{min} \end{bmatrix}$$

n_t : número de pasos temporales. n_c : número de subcuenas.

Entrenamiento global

Matriz de características:

$$X_{comp} = \begin{bmatrix} p_{1,1} & T_{1,1}^{max} & T_{1,1}^{min} & \dots & p_{1,nc} & T_{1,nc}^{max} & T_{1,nc}^{min} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ p_{nt,1} & T_{nt,1}^{max} & T_{nt,1}^{min} & \dots & p_{nt,n} & T_{nt,n}^{max} & T_{nt,nc}^{min} \end{bmatrix}$$

n_t : número de pasos temporales. n_c : número de subcuencas.

76 sub-cuencas, 20 años, paso mensual

Entrenamiento global

Matriz de características:

$$X_{comp} = \begin{bmatrix} p_{1,1} & T_{1,1}^{max} & T_{1,1}^{min} & \dots & p_{1,nc} & T_{1,nc}^{max} & T_{1,nc}^{min} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ p_{nt,1} & T_{nt,1}^{max} & T_{nt,1}^{min} & \dots & p_{nt,n} & T_{nt,n}^{max} & T_{nt,nc}^{min} \end{bmatrix}$$

n_t : número de pasos temporales. n_c : número de subcuencas.

76 sub-cuencas, 20 años, paso mensual → dimensión (229,228)

Entrenamiento global

Matriz de características:

$$X_{comp} = \begin{bmatrix} p_{1,1} & T_{1,1}^{max} & T_{1,1}^{min} & \dots & p_{1,nc} & T_{1,nc}^{max} & T_{1,nc}^{min} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ p_{nt,1} & T_{nt,1}^{max} & T_{nt,1}^{min} & \dots & p_{nt,n} & T_{nt,n}^{max} & T_{nt,nc}^{min} \end{bmatrix}$$

n_t : número de pasos temporales. n_c : número de subcuencas.

76 sub-cuencas, 20 años, paso mensual → dimensión (229,228)

reshape LSTM1 (*muestras, pasos de tiempo, características*):
(229,1,228)

Entrenamiento global

Matriz de variables objetivo:

Entrenamiento global

Matriz de variables objetivo:

$$Y_{comp} = \begin{bmatrix} q_{1,1} & q_{1,2} & q_{1,2} \dots & q_{1,nc} \\ \dots & \dots & \dots & \dots \\ q_{nt,1} & q_{nt,2} & q_{nt,2} \dots & q_{nt,nc} \end{bmatrix}$$

Entrenamiento global

Matriz de variables objetivo:

$$Y_{comp} = \begin{bmatrix} q_{1,1} & q_{1,2} & q_{1,2} \dots & q_{1,nc} \\ \dots & \dots & \dots & \dots \\ q_{nt,1} & q_{nt,2} & q_{nt,2} \dots & q_{nt,nc} \end{bmatrix}$$

n_t : número de pasos temporales. n_c : número de subcuencas.

Entrenamiento local

Matriz de características:

Entrenamiento local

Matriz de características:

$$X_{loc,id} = \begin{bmatrix} p_{1,id} & T_{1,id}^{max} & T_{1,id}^{min} \\ \dots & \dots & \dots \\ p_{nt,id} & T_{nt,id}^{max} & T_{nt,id}^{min} \end{bmatrix}$$

Entrenamiento local

Matriz de características:

$$X_{loc,id} = \begin{bmatrix} p_{1,id} & T_{1,id}^{max} & T_{1,id}^{min} \\ \dots & \dots & \dots \\ p_{nt,id} & T_{nt,id}^{max} & T_{nt,id}^{min} \end{bmatrix}$$

Donde id es el número de la sub-cuenca.

Entrenamiento local

Matriz de características:

$$X_{loc,id} = \begin{bmatrix} p_{1,id} & T_{1,id}^{max} & T_{1,id}^{min} \\ \dots & \dots & \dots \\ p_{nt,id} & T_{nt,id}^{max} & T_{nt,id}^{min} \end{bmatrix}$$

Donde id es el número de la sub-cuenca. \rightarrow dimensión (229,1,3)

Entrenamiento local

Matriz de variables objetivo:

Entrenamiento local

Matriz de variables objetivo:

$$Y_{loc,id} = \begin{bmatrix} q_{1,id} \\ \dots \\ q_{nt,id} \end{bmatrix}$$

Entrenamiento local

Matriz de variables objetivo:

$$Y_{loc,id} = \begin{bmatrix} q_{1,id} \\ \dots \\ q_{nt,id} \end{bmatrix}$$

Donde id es el número de la sub-cuenca.

Entrenamiento secuencial

- ▶ Sólo se utilizan los valores simulados de los caudales en la matriz $Y_{loc,id}$.
- ▶ La red utiliza los valores de los caudales en tiempos anteriores $q_{t-1}, q_{t-2}, q_{t-n}$ para predecir el valor actual q_t .

Entrenamiento secuencial

- ▶ Se toman los primeros 70% datos para train y los últimos 30% para test y se restructuran los conjuntos:

$$\begin{bmatrix} q_{1,id} \\ q_{2,id} \\ \dots \\ q_{nt,id} \end{bmatrix} \rightarrow X_{seq,id} = \begin{bmatrix} q_{1,id} & q_{2,id} & \dots & q_{lb,id} \\ q_{2,id} & q_{3,id} & \dots & q_{lb+1,id} \\ \dots & \dots & \dots & \dots \\ q_{nt-lb-1,id} & q_{nt-lb+1,id} & \dots & q_{nt-1,id} \end{bmatrix}$$

$$Y_{seq,id} = \begin{bmatrix} q_{lb+1,id} \\ q_{lb+2,id} \\ \dots \\ q_{nt,id} \end{bmatrix}$$

nt es la cantidad de muestras, y *lb* define cuantos valores del “pasado” se utilizan para predecir el próximo valor.

Entrenamiento secuencial

- ▶ La dimensión de los conjuntos es entonces: $(nt - lb - 1, lb)$ y $(nt - lb - 1,)$ para los conjuntos $X_{seq,id}$ y $Y_{seq,id}$, respectivamente.
- ▶ con el reshape para redes LSTM, la dimensión de $X_{seq,id}$ es $(nt - lb - 1, 1, lb)$.

Preparación de los datos

- ▶ Para evitar que las sub-cuencas que poseen mayores caudales dominen en el proceso de la optimización de loss, en todos los casos anteriores los datos han sido normalizados. Para esto se sustrae la media y se normaliza por la desviación estándar.

Preparación de los datos

- ▶ Para evitar que las sub-cuencas que poseen mayores caudales dominen en el proceso de la optimización de loss, en todos los casos anteriores los datos han sido normalizados. Para esto se sustrae la media y se normaliza por la desviación estándar.
- ▶ Para el caso del entrenamiento global, se ha realizado una reducción del espacio mediante el análisis de componentes principales.

Preparación de los datos

- ▶ Para evitar que las sub-cuencas que poseen mayores caudales dominen en el proceso de la optimización de loss, en todos los casos anteriores los datos han sido normalizados. Para esto se sustrae la media y se normaliza por la desviación estándar.
- ▶ Para el caso del entrenamiento global, se ha realizado una reducción del espacio mediante el análisis de componentes principales. → las primeras 9 componentes explican el 96% de la varianza.

Calibración

- ▶ Se ha realizado una búsqueda de los hyper-parámetros mostrados en la tabla utilizando el método "GridSearchCV"

Modelo	Parámetros	valores
Denso	solver	rmsprop, adam, sgd
	Neuronas	10, 80, 200
	activación	sigmoid,relu,tanh,linear
	alpha	0.0001,0.0002,0.0003
	Regularización	l1,l2 $\lambda = 0.0001, 0.001, 0.1$
LSTM1 PCA	solver	rmsprop, adam, sgd
	Neuronas	10, 80, 200
	activación	sigmoid,relu,tanh,linear
	alpha	0.0001,0.0002,0.0003
	Regularización	l1,l2 $\lambda = 0.0001, 0.001, 0.1$
LSTM1 loc	solver	rmsprop, adam, sgd
	Neuronas	10, 80, 200
	activación	sigmoid,relu,tanh,linear
	alpha	0.0001,0.0002,0.0003
	Regularización	l1,l2 $\lambda = 0.0001$
LSTM2	solver	rmsprop, adam, sgd
	Neuronas	10, 80, 200
	activación	sigmoid,relu,tanh,linear
	alpha	0.001

Validación

- ▶ se ha utilizado el coeficiente Nash-Sutcliffe (NSE) para evaluar la performance de los modelos en el conjunto de test

$$NSE = 1 - \frac{\sum_i^n (y_i - \hat{y}_i)^2}{\sum_i^n (\bar{y} - \hat{y}_i)^2} \quad (1)$$

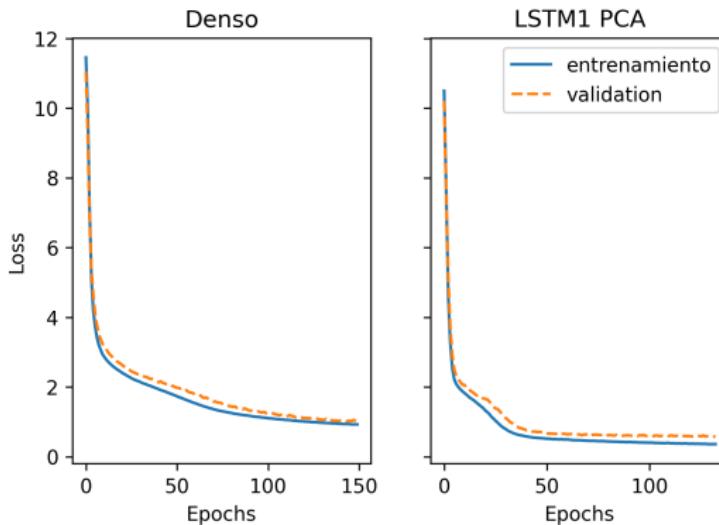
Calidad del ajuste	NSE
Excelente	$0.75 < NSE \leq 1.00$
Bueno	$0.65 < NSE \leq 0.75$
Aceptable	$0.5 < NSE \leq 0.65$
No aceptable	$NSE \leq 0.5$

Resultados

Hyper parámetros utilizados:

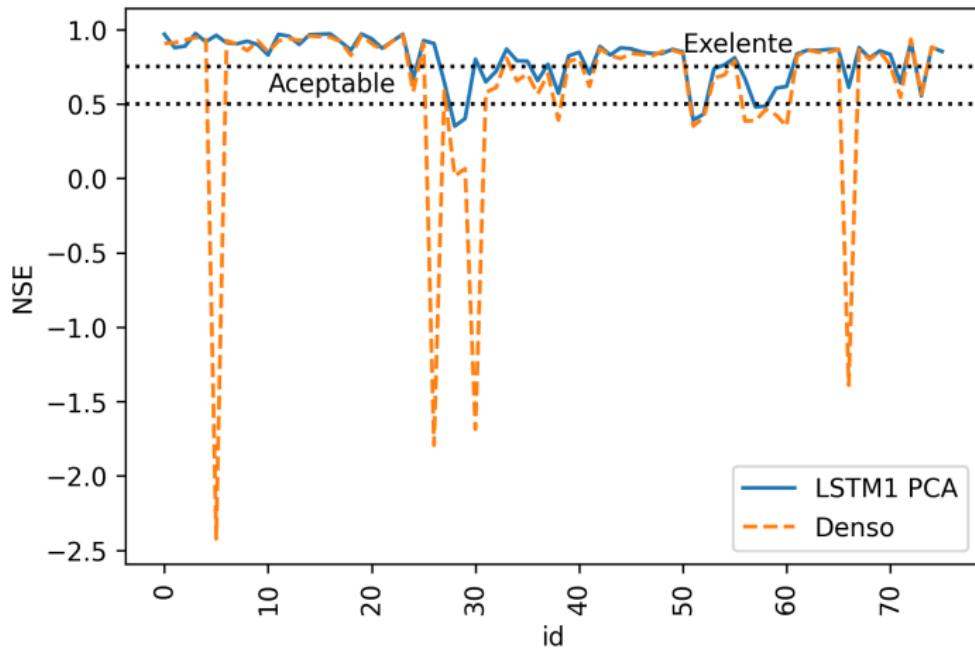
Modelo	optimizador	Neuronas	Activación	alpha	reg
Denso	rmsprop	200	relu	0.0002	$l2, 0.0001$
LSTM1 PCA	rmsprop	200	linear	0.0002	$l2, 0.0001$
LSTM1 loc	adam	200	relu	0.0001	$l1, 0.0001$
LSTM2	adam	200	relu	0.001	$l2, 0.0000001$

Evolución de la función Loss

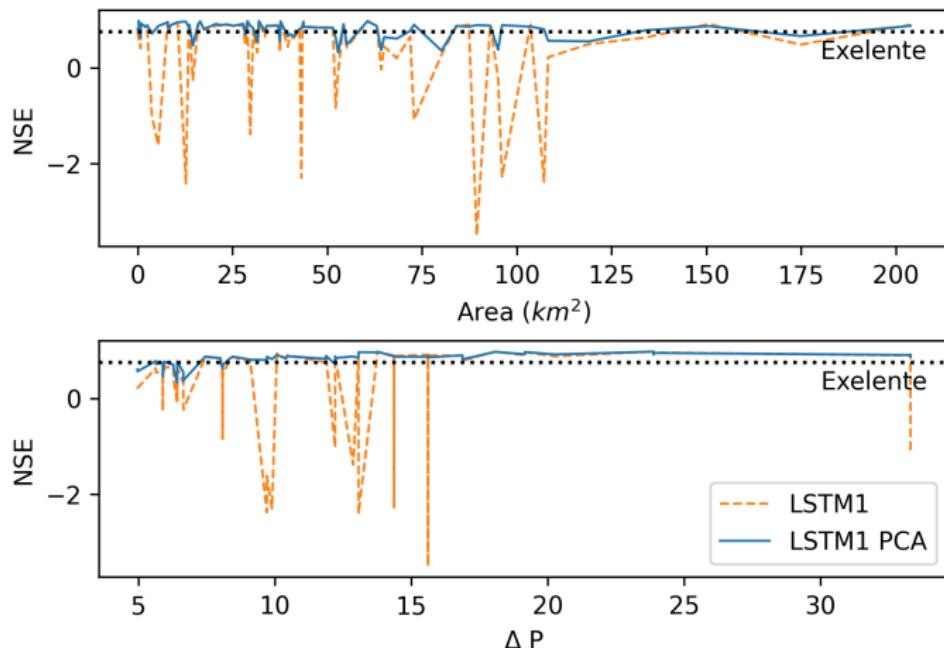


$$RMSE = \sqrt{\frac{\sum_{ij}(\hat{y}_{ij} - y_{ij})^2}{nt}}$$

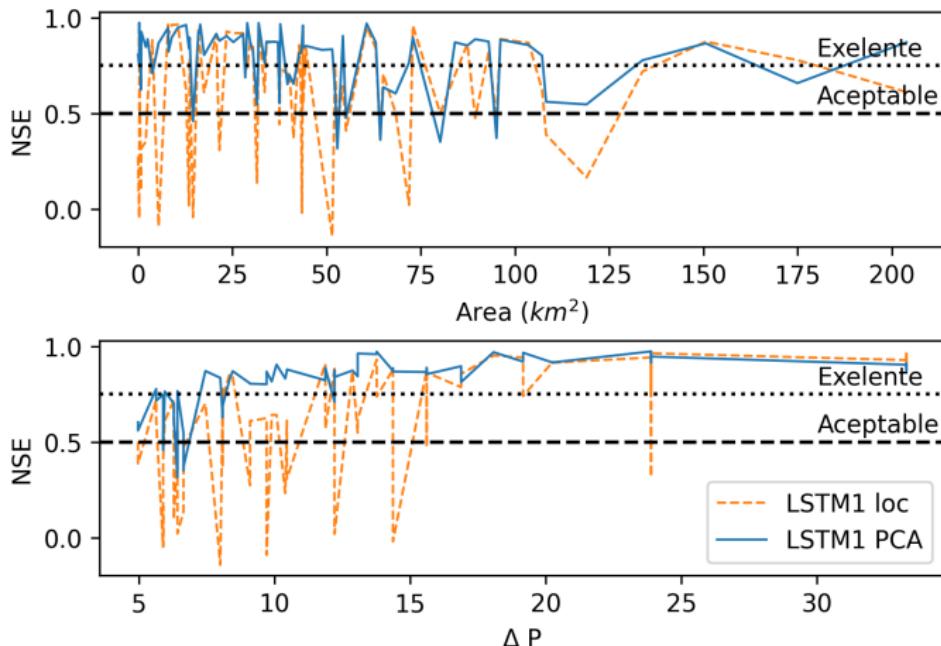
Validación



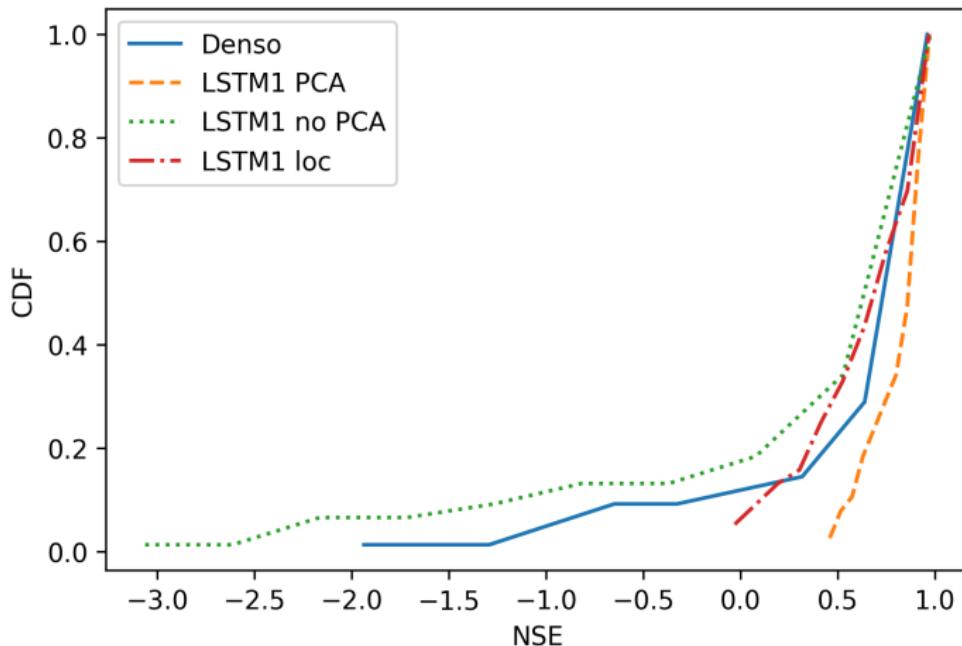
con/sin PCAs



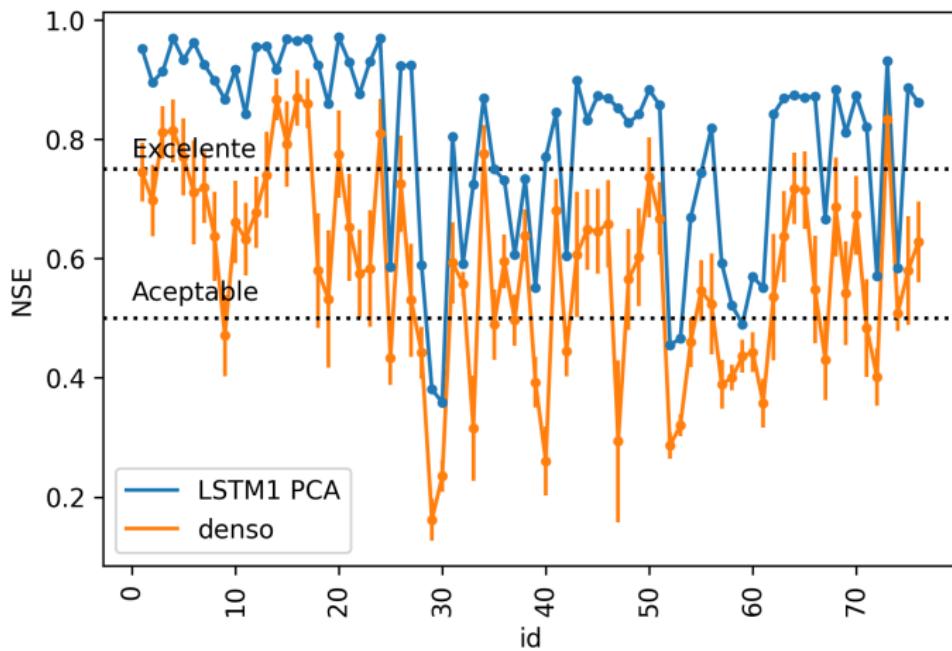
Entrenamiento loc/glob



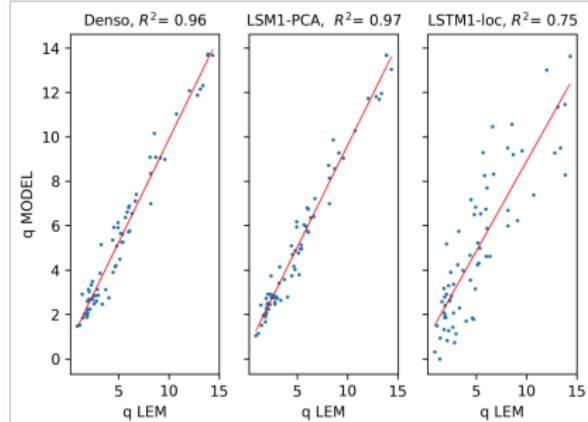
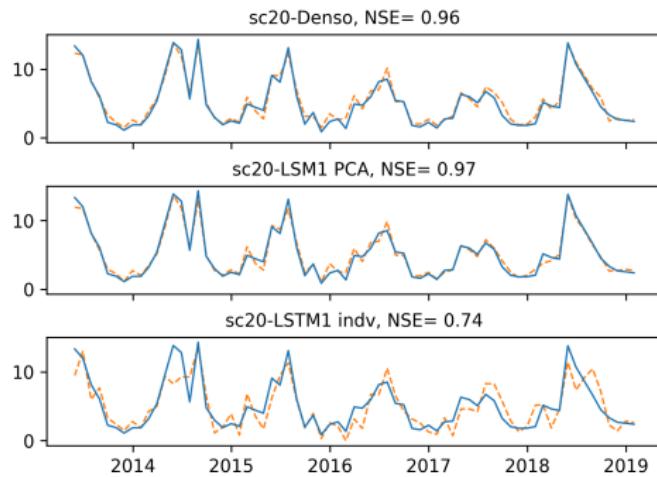
Función de distribución acumulada



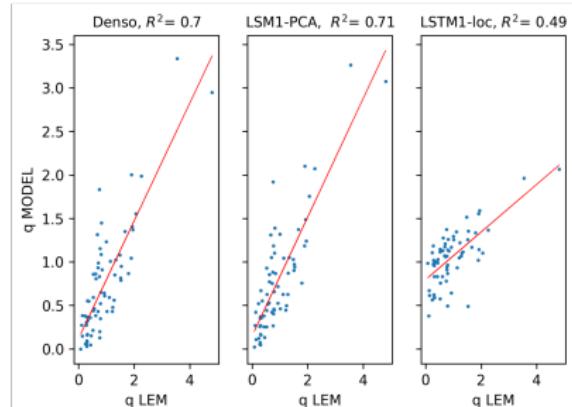
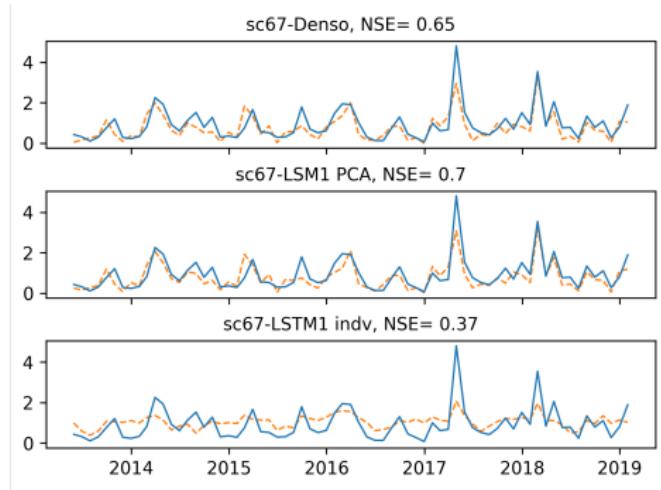
Validación - Ensemble



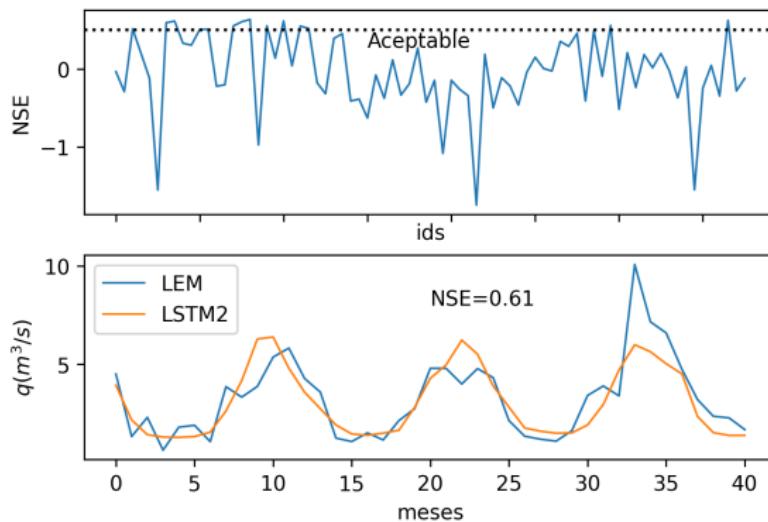
Caudales



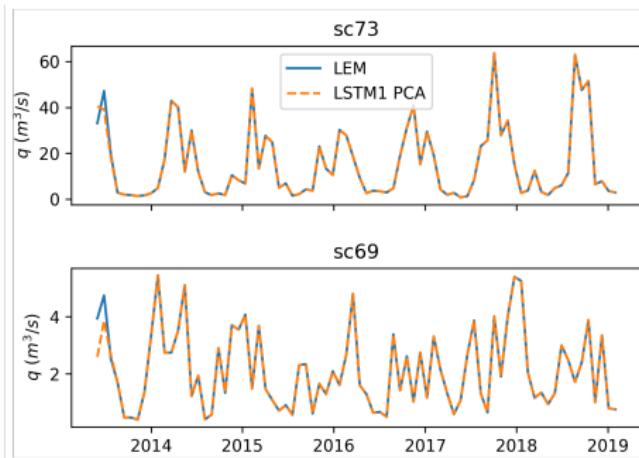
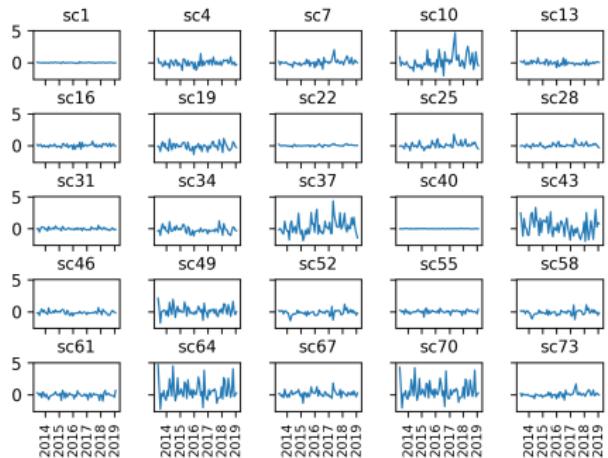
Caudales



Caudales-entrenamiento secuencial



Resultados: Caudales



Conclusiones

- ▶ El modelo que realiza los mejores ajustes es el LSTM1 con PCAs.

Conclusiones

- ▶ El modelo que realiza los mejores ajustes es el LSTM1 con PCAs.
- ▶ Los ajustes que se obtienen al entrenar los modelos globalmente son mejores que los que se obtienen al entrenarlos individualmente.

Conclusiones

- ▶ El modelo que realiza los mejores ajustes es el LSTM1 con PCAs.
- ▶ Los ajustes que se obtienen al entrenar los modelos globalmente son mejores que los que se obtienen al entrenarlos individualmente.
- ▶ El modelo LSTM2 seq. presenta una mala performance en la mayoría de los puntos.

Conclusiones

- ▶ El modelo que realiza los mejores ajustes es el LSTM1 con PCAs.
- ▶ Los ajustes que se obtienen al entrenar los modelos globalmente son mejores que los que se obtienen al entrenarlos individualmente.
- ▶ El modelo LSTM2 seq. presenta una mala performance en la mayoría de los puntos.
- ▶ El modelo LSTM1 PCA es capaz de reflejar los comportamientos hidrológicos regionales específicos de cada sub-cuenca combinando los datos de todas las sub-cuenca.

Conclusiones

- ▶ El modelo que realiza los mejores ajustes es el LSTM1 con PCAs.
- ▶ Los ajustes que se obtienen al entrenar los modelos globalmente son mejores que los que se obtienen al entrenarlos individualmente.
- ▶ El modelo LSTM2 seq. presenta una mala performance en la mayoría de los puntos.
- ▶ El modelo LSTM1 PCA es capaz de reflejar los comportamientos hidrológicos regionales específicos de cada sub-cuenca combinando los datos de todas las sub-cuenca.
- ▶ Los resultados obtenidos con el modelo LSTM1 PCA pueden ser utilizados para simular operaciones en la cuenca CHRC.

Conclusiones generales

- ▶ Las redes LSTM son idóneas para hacer modelos de precipitación/escorrentía.
- ▶ La inclusión de las celdas de memoria LSTM y la presencia de componentes principales mejoran notablemente la performance de los modelos en cuencas hidrográficas ya que:

Conclusiones generales

- ▶ Las redes LSTM son idóneas para hacer modelos de precipitación/escorrentía.
- ▶ La inclusión de las celdas de memoria LSTM y la presencia de componentes principales mejoran notablemente la performance de los modelos en cuencas hidrográficas ya que:
 1. Las celdas LSTM aprenden simultáneamente relaciones de series temporales y espaciales en el mismo marco predictivo.

Conclusiones generales

- ▶ Las redes LSTM son idóneas para hacer modelos de precipitación/escorrentía.
- ▶ La inclusión de las celdas de memoria LSTM y la presencia de componentes principales mejoran notablemente la performance de los modelos en cuencas hidrográficas ya que:
 1. Las celdas LSTM aprenden simultáneamente relaciones de series temporales y espaciales en el mismo marco predictivo.
 2. Las PCAs reducen la dimensión del espacio predictor combinando la información proveniente de todo el dominio del mismo.

Conclusiones generales

- ▶ Las redes LSTM son idóneas para hacer modelos de precipitación/escorrentía.
- ▶ La inclusión de las celdas de memoria LSTM y la presencia de componentes principales mejoran notablemente la performance de los modelos en cuencas hidrográficas ya que:
 1. Las celdas LSTM aprenden simultáneamente relaciones de series temporales y espaciales en el mismo marco predictivo.
 2. Las PCAs reducen la dimensión del espacio predictor combinando la información proveniente de todo el dominio del mismo.
- ▶ La principal virtud de las redes neuronales no es simplemente el hecho de que ajusten bien sino su capacidad de aprendizaje y flexibilidad para ser utilizadas en una variedad de lugares y condiciones diferentes.

Perspectivas futuras

- ▶ Se han comparado las performances entre diferentes modelos DL, en el futuro se propone comparar la performance predictiva de los modelos de DL con el modelo MELCA utilizando datos observados del caudal.

Perspectivas futuras

- ▶ Se han comparado las performances entre diferentes modelos DL, en el futuro se propone comparar la performance predictiva de los modelos de DL con el modelo MELCA utilizando datos observados del caudal.
- ▶ Concatenar los descriptores estáticos de las sub-cuenca, como por ejemplo el área, la longitud del cauce, etc., al espacio predictor.

Perspectivas futuras

- ▶ Se han comparado las performances entre diferentes modelos DL, en el futuro se propone comparar la performance predictiva de los modelos de DL con el modelo MELCA utilizando datos observados del caudal.
- ▶ Concatenar los descriptores estáticos de las sub-cuencas, como por ejemplo el área, la longitud del cauce, etc., al espacio predictor.
- ▶ Entrenar los modelos en un número mayor de cuencas de diferentes regiones y características y evaluar su performance en cuencas en donde no hayan visto sus datos de entrenamiento.

Perspectivas futuras

- ▶ Se han comparado las performances entre diferentes modelos DL, en el futuro se propone comparar la performance predictiva de los modelos de DL con el modelo MELCA utilizando datos observados del caudal.
- ▶ Concatenar los descriptores estáticos de las sub-cuencas, como por ejemplo el área, la longitud del cauce, etc., al espacio predictor.
- ▶ Entrenar los modelos en un número mayor de cuencas de diferentes regiones y características y evaluar su performance en cuencas en donde no hayan visto sus datos de entrenamiento.